DataDiet-EHR：临床文本训练的数据冗余度评估与训练子集选择软件

研制（究）报告

参赛类别：科技发明制作 B 类

作品形态：软件系统（含可复现协议文档、审计工具链）

关键词：数据裁剪、神经元激活、训练子集选择、等效性检验、临床文本、算力预算

一、作品概述

本作品是一套能直接跑的软件，用来回答一个具体问题：临床文本模型训练时，能不能少用一大半数据，还把效果保持住？

它由三部分组成：

1. Python 侧（23 个模块，约 3,500 行）：数据清洗与切分 → 神经元激活采集 → 训练子集选择 → LoRA 微调 → 逐题评测 → 结果入账，一条命令跑完一个实验单元（`run_one.py`）。

2. R 侧（8 个脚本，base R 零第三方依赖）：逐题配对检验、自助法置信区间、等效性检验（TOST）、跨种子合并、Holm 多重比较、以及全部论文图表的生成。

3. 审计与调度层：选择日志（每次挑选都留哈希与统计量）、产物哈希清单、断言式体检脚本（75 项）、夜间队列与断点续跑。

软件不追求"更大的模型"，而是把"用多少数据才够"变成可测

量、可复现、可审计的一件事。

主要技术指标（48,000 条训练池，保留 30%）：

指标	结果
主任务（MedMCQA 4,183 题）掉点	−0.96 pp，95% CI [−1.77, +0.22]，落在 ±2pp 等效界内
同规模随机抽样对照	−1.45 pp，CI [−2.39, −0.53]，下界越界
与随机对照的差值	+0.50 pp（Stouffer p = 0.016，Holm 校正后 0.064，未达显著）
端到端算力（含选择开销）	2.082 → 1.080 GPU-h，净省 48.2%
评测可复现性	逐题预测 46 份、产物哈希 60+ 条、数字可溯源 100%

二、研制目的与意义

2.1 临床 AI 的真实瓶颈是训练预算，不是模型结构

医院信息科或模型团队要微调一个临床文本模型（病历摘要、出院小结、编码辅助），成本主要由三块构成：数据标注与脱敏、GPU 训练时长、以及反复试错的迭代次数。其中训练时长与数据量近似线性：48,000 条样本、3B 级模型、单卡笔记本，一个 epoch 就要 0.625 GPU·小时；真实院内语料动辄十万到百万条，一次全量训练就是数天。

2.2 冗余是真实存在的，但没人量化

医患问答、出院小结这类文本有极强的模板与复述特征：同一个"胸痛待查"的问法会有几十个变体，同一位病人的多次入院记录高度重叠。我们的实测：48,000 条池子里，语义近重复（余弦 > 0.95，去均值后）只占 2.68%，但文本长度、引用格式、章节结构的高度同

质让"随机抽样"也能拿到接近全量的效果——这正是很多团队"感觉砍一半也没事"的来源。

问题在于："感觉没事"不是证据。要写进科室预算、要通过伦理与质量审查，需要的是带置信区间的等效性结论。

2.3 现有方法有三个缺口

1. 协议不可复现：多数数据裁剪论文只给方法、不给可执行流程；换个数据集、换个人实现，结论就变。

2. 对照缺失：只报"我们的方法比基线好"，不报"随机抽样能做到多少"。而随机抽样恰恰是最便宜的基线。

3. 算力账不诚实：把"训练省了 70%"当成结论，却不扣"挑数据本身要跑一遍模型"的开销。我们实测：基于激活的选择只要 0.455 GPU·小时，而基于全词表概率的 EL2N 要 0.607 GPU·小时——选择方法贵不贵，直接决定净收益是 48% 还是 11%。

本作品的目标就是补这三个缺口：给协议、给对照、给净账。

三、当前国内外同类研究水平概述

方向	代表工作	做法	与我们的差异
神经元激活选择	*Neuron-Aware Data Selection in Instruction Tuning*（Nait, ICLR 2026）	用目标域数据的激活模式做特征，按相似度选样本	我们复现其机制并接入临床文本流水线；不声称与官方实现对比（官方暂无可运行代码）
难度/影响函数	EL2N、GraNd（Paul et al., 2021）	用早期训练误差/梯度范数给样本打分，剪掉"简单样本"	我们把它做成对照臂，并如实报告它在本任务上输给随机、且不省钱

梯度相似度	LESS（Xia et al., 2024）	用低维梯度特征做可迁移选择	需额外参考训练与梯度存储，8GB 笔记本不可行，列为后续
语义去重	SemDeDup（Abbas et al., 2023）	嵌入聚类去重	我们把它并入协议第一步（去均值后阈值 0.95）
数据裁剪综述	Data Pruning 综述（Joshi et al.）	系统梳理"剪枝 vs 选子集"	我们的差异在等效性统计口径与净算力核算
临床语料	MIMIC-III/IV、MedQA、MedMCQA	公开临床文本与考题	我们用公开题库做主实验，院内 EMR 作为限制写明（见第八节）

水平判断（如实）：在"数据裁剪"这个方向上，方法层面的新颖性属于中上（激活特征 + 分层配额），但我们真正的贡献在工程与统计：把一整条链路做到可复现、把对照做全、把算力账算净。这三件事在同类工作中普遍缺失，也正是能落地的部分。

四、研制过程

4.1 总体架构

作品是六段流水线（图 1，见附件）：

```
训练池 → 激活采集 → 选择协议 → LoRA 训练 → 评测 → 统计
                                                  ↘ 随机对照 / 长度匹配对照 / EL2N 基线
```

每一段的输入输出都是文件契约（JSONL / NPZ / CSV /

JSON），不靠内存传递，因此任何一段都能单独替换、单独复跑、单独审计。

4.2 数据层

- 训练池：MedMCQA 训练集（182,822 条，含 21 个科室标签），按固定种子打乱后取 48,000 条作训练池、2,000 条作选择用探针集（probe）。
- 评测集：MedMCQA 测试+验证集 10,333 条中筛出 4,183 条有合法答案的题（同域主任务）；MedQA（USMLE Step 1）1,273 题（跨任务迁移）。
- 防泄漏：训练/探针/评测三者的题干做重叠检查，实测重叠 0 / 1 / 6 条（0.00% / 0.02% / 0.03%），并写进数据卡。
- 清洗：精确去重后保留率 97.32%（46,714 / 48,000）。

4.3 激活采集（本作品的核心工程之一）

- 取模型第 8、12、16、20、24 层的隐藏态；
- 只对回答（response）的 token 取平均，避免题干模板把信号稀释；
- 采集时使用基座模型（不做前向训练），48,000 条耗时 25.7 分钟；
- 关键技术点：去均值（anisotropy 校正）。大模型隐藏态方向高度集中，原始余弦相似度普遍在 0.95 以上，直接用阈值去重会误删 85% 的样本（我们第一版就踩了这个坑：12,000 条里删到只剩 1,811 条）。减去池内每层均值后再归一化，随机样本对

的余弦中位数从 0.95 降到 −0.01，阈值才恢复判别力。

4.4 选择协议

三段式，全部参数写进协议文档：

1. 语义去重：去均值后余弦 > 0.95 视为重复，保留首次出现的样本；

2. 分层配额：按科室占比分配名额（保证小科室不被整体剪掉）；

3. 簇内取分：每候选用"与探针集激活中心的余弦"打分，按分数降序取满。

消融结论（重要）：把第 2 步去掉、直接取全局前 30%，结果没有变化（MedMCQA −0.81 vs −0.96，逐题配对 $p > 0.4$）。因此分层配额在本任务上可省，协议可以简化——我们把这条写进了报告，而不是藏起来。

4.5 训练

- 基座：Qwen2.5-1.5B-Instruct（15 亿参数，bf16 约 3.1 GB）；
- 微调：LoRA，r=16、α=32、dropout 0.05，作用于全部 7 个线性投影，可训练参数 18,464,768 / 1,562,179,072 = 1.18%；
- 上下文 512（实测 98.4% 样本 ≤512）、批大小 4 × 梯度累积 2、学习率 1e-4 OneCycle、1 epoch；
- 只对回答算损失，指令部分 mask 掉。

4.6 评测

- 选项判别：单次前向取最后一个位置的 logits，比较 `" A"`…`" D"` 四个 token 的 log 概率，不生成文本，快且确定；
- 生成式：贪心解码 160 token，解析答案字母，同时统计格式合规率与四条红旗（擅自停药/超量用药/劝阻就医/武断诊断）；
- 每条题都落盘 `item_id, dept, pred, correct, pA..pD`，后续统计全部基于逐题预测，不允许手抄汇总数字。

4.7 统计口径（本作品与同类工作的最大差异）

环节	做法	为什么
单次比较	逐题配对 + 精确 McNemar	同一批题被两个模型答过，只有"答得不一致"的题携带信息
置信区间	逐题 bootstrap 2,000 次	不假设正态；同时给"种子级"CI（把种子当抽样单位）
等效性	TOST， δ = 2pp	先定界再跑，避免"跑完挑指标"； δ 由功效分析定（逐题差方差约 0.37，1,273 题 × 6 种子的 CI 半宽约 1.1–1.3pp）
跨种子	Stouffer 合并，禁止把 3×4183 当独立样本合并	会低估方差、虚高显著性（我们第一版就犯过，已改正并写进协议）
多重比较	Holm 校正，按"主终点/方法对比/其余比例"划分家族	主终点不校正，探索性对比必须校正

4.8 工程实现（在 8 GB 笔记本上跑完 100+ 个训练）

这是作品能落地的前提，也是最花时间的部分：

• 显存：3B 模型（权重 6.19 GB）在本机不可训（实测峰值 7.30–9.47 GiB > 8.15 GiB），改用 1.5B；给出三条替代路径（借 ≥12 GB 机器 / 租 4090 / QLoRA 4-bit）。

• 供电：笔记本未插电时功率上限 40 W，GPU 只有 202 MHz、吞吐掉 3–10 倍。软件在训练日志里打印峰值显存，配合 `powercfg` 检查清单，避免"跑了一夜其实在爬"。

• 夜间队列：`night_queue.py` 按（方法，保留率，种子）排队，跳过已完成项，单条失败不阻塞；每个 run 独立日志。

• 断点恢复：adapter 与逐题预测按 `exp_id` 命名，重启后自动跳过；实测断电两次、崩溃三次，无数据损坏。

• 审计链：每次选择写 `selection_log.jsonl`（含输入激活哈希、子集哈希、去重保留率、科室分布）；产物写 `ARTIFACTS.sha256`；`verify.py` 75 项断言、`audit_final.py` 六段交叉核对（含"文档里的每个数字能否在 CSV 里找到"）。

五、试验结果

5.1 主终点：30% 保留率下保持等效

48,000 条池、保留 30%（14,400 条）、6 个随机种子、δ = 2pp：

任务	方法	全量	30%	掉点	逐题 95% CI	逐题等效	种子等效
MedMCQA	本作品（激活选	0.4598	0.4545	−0.96 pp	[−1.77, +0.22]	✅	✅

	择）						
MedMCQA	随机抽样	0.4598	0.4551	−1.45 pp	[−2.39, −0.53]	❌	✅
MedQA	本作品	0.4809	0.4784	+0.04 pp	[−2.52, +1.26]	❌（样本少、CI 宽）	✅
MedQA	随机抽样	0.4809	0.4781	−0.24 pp	[−2.36, +1.18]	❌（同上）	✅

结论一：在 30% 保留率下，激活选择在 6 个种子上都保持等效（最坏单种子 −1.58pp，仍在界内）；随机抽样则在 6 个种子上都掉出边界。"少用七成数据"这件事，需要选，不能随便抽。

5.2 与随机对照的差值

MedMCQA 上：+0.50 pp，95% CI [−0.04, +1.03]，Stouffer p = 0.016，Holm 校正后 0.064（未达显著）。

但 6 个种子里有 1 个方向相反（−0.36pp），因此我们只主张"方向有利于激活选择，但证据尚不够硬"，不主张"稳定优于随机"。这条边界我们在正文、图表、答辩口径里统一写明。

5.3 算力净账（本作品主张"诚实核算"）

方法	训练	选择前向（一次性）	合计	相对全量净省
全量 48k	2.082	—	2.082 GPU-h	0
随机 30%	0.625	0	0.625	70.0%
本作品 30%	0.625	0.455	1.080	48.2%
EL2N 30%	0.625	0.607	1.232	10.8%（在 24k 轮实测）

结论二：真正能兑现的是约 48%，不是"省 70%"。差的这 22 个

百分点，就是"多看一遍模型"的代价——这是所有"数据裁剪省算力"宣传里被系统性忽略的一项。

5.4 消融与失败诊断（作品的一部分，而不只是附录）

实验	结果	说明
去掉分层配额	−0.81 vs −0.96，p > 0.4	分层可省，协议可简化
长度匹配随机（rand_len）	−0.15（MedMCQA）	长度不是机制：把长度分布对齐后，随机依然不如激活选择
EL2N 基线	−1.04 / −1.05；比随机差 0.80pp（Holm 0.025）	"挑最难的样本"在本任务上输给随机：所谓"难"多半是题干含糊或标注噪声
生成式评测（500 题）	本作品 47.0% / 随机 49.4% / 全量 48.8%	能力无差异；但本作品输出中位 68 token、引用样式出现率显著更高——激活选择放大的是"文献腔"，不是能力

结论三：这条"失败诊断"是本作品最有价值的发现之一——它解释了为什么方法间差异这么小，也提醒使用者：激活相似度筛的是文本装置（引用、页码、书名），不是题目价值。

5.5 图表

- 图 1 六段流水线（原理结构图）
- 图 2 数据效率曲线（探索性，仅 30% 有 6 种子）
- 图 3 逐任务/逐科室掉点（点 + 区间）
- 图 4 算力净账（堆叠柱：训练 + 选择前向）
- 图 5 逐种子森林图（6 种子 + 合并均值）
- 图 6 混淆/样例（生成式输出对照）

六、创新点

1. 把"能省多少数据"做成带置信区间的等效性结论（TOST + 逐题配对 + 种子级 CI），而不是"我们的方法更好"。

2. 算力净账口径：把选择前向开销计入，并按方法分别实测——同样的"30% 保留"，净省可以是 48% 也可以是 11%。

3. 各向异性校正后的激活选择：去均值让去重阈值恢复判别力（本项目从"误删 85%"修正到"删 2.68%"）。

4. 可审计的流水线：选择日志 + 产物哈希 + 75 项断言 + 文档数字溯源，任何人拿到仓库都能复跑并核对每个数字。

5. 诚实的负结果：EL2N 输给随机、分层配额无贡献、激活选择放大风格而非能力——这些都在正文里，而不是删掉。

七、实际应用情况与应用前景

7.1 已具备的落地形态

- 一条命令完成"选数据 → 训练 → 评测 → 入账"，换数据集只需替换 `data/processed/` 下的四个 JSONL 并重跑三条命令，代码零改动；
- 已在院内场景的替身数据上端到端演练（合成出院小结 196 份，2.6 毫秒/份，含伪 ID、章节抽取、按病人切分、泄漏检查全部通过）；
- 软著登记材料已备（源程序 3,468 行、说明书 12 页），正在申请。

7.2 成本模型（可按医院规模外推）

场景	数据量	全量训练	本作品 30%	净省
本次实验（1.5B，单卡笔记本）	48k	2.08 GPU-h（约 4 元）	1.08 GPU-h	48%
院内中等规模（3B，A100）	200k	约 40 GPU-h（约 2,000 元）	约 21 GPU-h	约 48%
多轮迭代（10 次实验）	200k	400 GPU-h	210 GPU-h	省约一半预算与一半等待时间

对信息科的意义：同样的卡，能多跑一倍的迭代；对模型团队的意义：把"要不要减数据"从直觉变成可签字的技术结论。

7.3 推广路径

1. 横向：换语料（出院小结、影像报告、护理记录）不改代码，只需重跑数据准备与选择；

2. 纵向：与院内模型训练流水线对接，把"选择 + 净账"作为训练前的标准步骤；

3. 对外：协议文档 + 开源仓库（MIT 许可，数据不入库）可作为同类项目的起点。

八、存在不足与下一步工作

1. 数据不是院内电子病历：主实验用公开题库（MedMCQA / MedQA），院内 EMR 需伦理批件与数据使用协议，尚未获得。已在数据卡与正文中作为限制写明，并给出 MIMIC-IV 的申请清单与"数据到手当天"执行手册。

2. 单 epoch、单基座：1.5B + 1 epoch 是为了让 100+ 个 run 在单卡上可完成；3-epoch 轮已跑（2 种子），3B 因 8 GB 显存不可行，三条替代路径已写明。

3. 剂量-反应曲线不可识别：10/20/50/70% 只有单种子，单点摆动能到 ±1.5pp，因此只对 30% 下结论，其余标注为探索性。

4. 评测偏"选择题 + 500 题生成式"：真实临床价值需要专家评分与安全性评估，生成式评测的四条红旗只是粗筛。

5. 下一步：真病历接入 → 跨基座（≥12 GB 卡）→ 3 epoch 六种子 → 专家评分。

九、图表与附件清单

附件	内容	位置
图 1	六段流水线与三条对照臂	`paper/figures/fig01_pipeline.png`
图 2	数据效率曲线（探索性）	`fig02_data_efficiency.png`
图 3	逐科室掉点	`fig04_dept.png`
图 4	算力净账（堆叠柱）	`fig05_compute.png`
图 5	逐种子森林图	`fig06_forest.png`
表 1	主终点等效性（6 种子）	`paper/table1.md`
表 2	方法对比与 Holm 校正	`results/eq_contrast.csv`
表 3	算力净账	`results/compute_table.csv`
附件 A	软著登记材料（源程序 3,468 行 + 说明书）	`softcopyright/`
附件 B	可复现协议 v1.0	`docs/PROTOCOL.md`
附件 C	数据卡（五个数据源与合规红线）	`docs/DATA_CARD.md`

附件 D	主张-证据矩阵（每条结论对应哪个 CSV）	`docs/CLAIM_EVIDENCE.md`

十、参考文献

1. Chen X. et al. *Neuron-Aware Data Selection in Instruction Tuning for Large Language Models.* ICLR 2026 (poster).

2. Paul M. et al. *Deep Learning on a Data Diet: Finding Important Examples Early in Training.* NeurIPS 2021.

3. Xia M. et al. *LESS: Selecting Influential Data for Targeted Instruction Tuning.* ICML 2024.

4. Abbas A. et al. *SemDeDup: Data-efficient learning at web-scale through semantic deduplication.* 2023.

5. Joshi A. et al. *Data Pruning: A Survey.* 2024.

6. Pal A. et al. *MedMCQA: A Large-scale Multi-Subject Multi-Choice Dataset for Medical Domain Question Answering.* CHIL 2022.

7. Jin D. et al. *What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams (MedQA).* Applied Sciences 2021.

8. Hu E. J. et al. *LoRA: Low-Rank Adaptation of Large Language Models.* ICLR 2022.

9. Johnson A. et al. *MIMIC-IV, a freely accessible electronic health record dataset.* Scientific Data 2023.

10. Qwen Team. *Qwen2.5 Technical Report.* 2024.