专利交底书（草稿 v0.1）

用途：给专利代理人看的"技术底稿"。代理所据此撰写权利要求书与说明书。

本文件由项目实测数据支撑，所有数字均可在 `results/` 与 `paper/` 中溯源。

一、发明名称

一种面向临床文本模型训练的神经元激活子集选择方法及系统

（备选：一种训练数据裁剪与算力调度方法、装置及存储介质）

二、技术领域

机器学习模型训练数据的筛选与训练资源调度，具体涉及面向临床医学文本的大语言模型指令微调阶段的训练样本子集选择。

三、背景技术与现有技术的缺陷

临床机构微调医学大模型时，训练语料冗余度高、标注成本高，全量训练算力开销大。现有做法有三类缺陷：

1. 基于训练误差的样本打分（EL2N / GraNd）：需要模型对每个样本输出全词表 logits 再做 softmax，一次选择前向的开销接近甚至超过"省下的训练开销"。本申请实测：在 24,000 条语料、1.5B 参数模型上，EL2N 的选择前向耗时 0.607 GPU-h，是激活式方案的 2.4 倍，导致净算力节省从 45% 衰减到 10.8%。

2. 随机抽样：开销为零但不可控，无法保证跨科室、跨任务的覆盖，且无法审计"选了谁、为什么选"。

3. 基于隐藏层激活的相似度选择：直接对激活向量做余弦相似度会失效——大模型隐藏态存在强各向异性（几乎所有样本共享一个主方向），任意两条样本的余弦相似度天然接近 0.95 以上。本申请实测：未做校正时，固定阈值 0.95 会把 85% 的样本误判为重复（12,000 条里只保留 1,811 条）。

此外，现有方案普遍只报告"少用了多少数据"，未把选择阶段自身的算力开销计入净节省，导致宣称的节省与实际账不符。

四、发明内容

4.1 要解决的技术问题

在显存受限（如 8 GB 消费级显卡）的临床场景下，如何以可审计、低开销的方式从大规模临床文本语料中选出训练子集，使得在保持下游医学任务效果的前提下，显著降低端到端训练算力。

4.2 技术方案（六个步骤）

- S1 池化与切分：将临床语料按病人/题目归属切分为训练池与留出探针集（probe），确保同一实体不跨集合；训练池规模可配置（本申请实测 12k / 24k / 48k 三档）。
- S2 激活采集：以冻结基座模型对训练池做一次前向，仅在响应片段（response token）上取均值，抽取第 {8,12,16,20,24} 层的隐藏态，得到每样本的 5×d 激活矩阵；同时在同一前向中

采集留出探针集的激活，用于构造目标域"期望激活模式"。

- S3 各向异性校正：对每一层计算训练池内的激活均值向量 μ_l，将全部样本激活减去 μ_l 后再做 L2 归一化。此步骤是方案可用的前提（见 3.3 的对比数据）。
- S4 打分：以留出探针集的层均值作为期望模式 c_l，样本得分 s_i = mean_l cos(ā_{i,l}, c_l)，其中 ā 为校正后的激活。
- S5 语义去重：在校正后的空间里，将余弦相似度超过阈值（实施例取 0.95）的样本判为重复，保留先出现者。校正后该阈值只剔除约 1.6%–2.7% 的样本，符合"只去真重复"的预期。
- S6 分层配额 + 取前 k：按科室（或 ICD 章节）比例分配名额，在每个层内按得分降序取满，得到最终保留比例 k 的子集；k 由"算力预算"反解，而不是固定常数。

4.3 有益效果（均为实测）

指标	本方案	对照
30% 保留下的准确率下降	−0.96 pp，95% CI [−1.77, +0.22]（6 个随机种子）	EL2N −1.04 pp 且置信区间更宽
端到端算力净节省	48.2%（2.082 → 1.080 GPU-h，含选择前向 0.455 GPU-h）	EL2N 仅 10.8%
选择阶段开销	0.455 GPU-h / 48k 条	EL2N 0.607 GPU-h / 24k 条（单位成本高 2.4 倍）
可审计性	逐样本激活得分、子集 id、选择日志（哈希链）	随机抽样不可审计

配合本方案的训练实现（LoRA、长度分桶批处理、梯度检查点），可在 8 GB 显存的单卡笔记本上完成 48,000 条语料的微调，这是同类方案未报告的技术效果。

五、附图

- 图 1：整体流程（`paper/figures/fig01_pipeline.png`）
- 图 2：不同保留比例下的效果曲线（`fig02_data_efficiency.png`）
- 图 3：算力净账堆叠柱（`fig05_compute.png`）

六、具体实施例

实施例 1：基座 Qwen2.5-1.5B-Instruct，LoRA（r=16，α=32，作用于 q/k/v/o/gate/up/down 七类投影），bf16，序列长度 512，批 4×2，学习率 1e-4（OneCycle），1 个 epoch；训练池 48,000 条（MedMCQA 训练集切分），评测 MedMCQA 4,183 题 + MedQA 1,273 题；k=30%，取 14,400 条。

七、权利要求草案（供代理人参考）

1. 一种临床文本模型训练子集选择方法，其特征在于，包括：S1 按实体归属切分训练池与留出探针集；S2 以冻结基座模型对训练池做单次前向，仅在响应片段上取均值并抽取预设多层隐藏态；S3 对每层减去该层池内均值后再归一化；S4 以留出探针集的层均值构造期望模式，按层余弦相似度均值打分；S5 在归一化空间内按阈值

去重；S6 按科室比例分配名额后按得分降序取满，得到保留比例为 k 的子集。

2. 根据权利要求 1 的方法，其特征在于，步骤 S6 中 k 由给定的算力预算反解，且预算计算包含选择阶段前向的开销。

3. 根据权利要求 1 的方法，其特征在于，步骤 S2 所述预设多层为 {8,12,16,20,24} 层。

4. 一种训练数据筛选与算力调度系统，包括存储器和处理器，所述存储器存储计算机程序，所述处理器执行时实现权利要求 1－3 任一项所述方法。

5. 一种计算机可读存储介质，其上存储的计算机程序被处理器执行时实现权利要求 1－3 任一项所述方法。

八、新颖性风险与规避说明（内部用，不提交）

1. 已知最接近的现有技术：*Neuron-Aware Data Selection in Instruction Tuning for Large Language Models*（Nait, ICLR 2026）。它同样使用激活模式相似度选子集，但公开内容未涉及：各向异性校正、按科室分层配额、把选择开销并入 k 的求解、以及在临床选择题池上的等效性判据。

2. 本申请必须落在"具体技术手段"上，不能写成"用激活相似度选数据"这种抽象规则（会被认定为智力活动规则，落入《专利法》第 25 条）。

3. 公开时点：中国专利法第 24 条规定，在规定的学术会议或

技术会议上首次发表，6 个月内不丧失新颖性；但校赛材料、公开仓库、预印本不在此列。结论：先递交申请拿受理号，再公开。

4. 授权前景评估（诚实版）：软件类方法专利审查趋严，独立权利要求 1 存在被以"数据处理算法"驳回的风险；建议把权 2（算力预算反解 + 计入选择开销）与权 3（具体层选择）作为核心区别技术特征写入独立权项，提高创造性论据强度。